

A análise de desempenho de vendas e previsão de atrasos em entregas no e-commerce brasileiro

Relatório técnico - Parte teórica e metodologia prática

Instituição: Faculdade UniFECAF

Disciplina: Programming for Data Science (Python & R)

Aluno: Antônio Benevaldo Chaves Santana

Professor: Matheus Santos

Curso: Ciência de Dados

Resumo

Este trabalho propõe uma solução de Ciência de Dados para analisar o desempenho de vendas da Olist e estimar, no momento da compra, o risco de um pedido ser entregue após a data prometida. O projeto integra tabelas relacionais de pedidos, itens, clientes, vendedores, produtos, pagamentos e geolocalização; trata ausências, duplicidades, inconsistências e valores extremos; investiga padrões temporais, regionais e operacionais; e compara modelos de classificação. Para preservar a validade do uso empresarial, variáveis geradas depois da entrega, como a avaliação do cliente, são utilizadas apenas na análise descritiva e excluídas da predição. A validação é temporal, simulando a aplicação do modelo em pedidos futuros. A análise descritiva cobre ainda sazonalidade por mês e por dia da semana, forma de pagamento e nota média do vendedor, respondendo diretamente às questões propostas no enunciado. O notebook entregue automatiza a preparação, os gráficos, a avaliação e a geração das recomendações, que são montadas em tempo de execução com os estados, categorias, formas de pagamento e métricas efetivamente obtidos.

Palavras-chave: ciência de dados; comércio eletrônico; logística; classificação; atraso de entrega; Olist.

1. Introdução

O crescimento do comércio eletrônico amplia a necessidade de coordenar vendedores, transportadores, centros de distribuição e clientes espalhados por regiões com diferentes condições de infraestrutura. Quando a entrega ultrapassa a data prometida, a empresa pode enfrentar aumento de reclamações, reembolsos, contatos ao suporte e perda de confiança. Nesse contexto, a previsão antecipada de risco permite priorizar pedidos, revisar prazos e direcionar ações preventivas.

O conjunto Brazilian E-Commerce Public Dataset by Olist reúne aproximadamente 100 mil pedidos realizados entre 2016 e 2018 e contém dados anonimizados sobre várias dimensões da operação. Por ser composto por tabelas relacionais com granularidades distintas, seu uso exige decisões cuidadosas de integração. Um pedido pode conter vários itens, pagamentos e avaliações; uma junção direta de todas as tabelas pode multiplicar linhas e distorcer totais. Por isso, cada conjunto é agregado para a granularidade de pedido antes da integração final.

1.1 Problema de negócio

O problema analítico é uma classificação binária: prever se um pedido entregue terá atraso. A variável-alvo é definida por $\text{atraso} = 1$ quando $\text{order_delivered_customer_date} > \text{order_estimated_delivery_date}$ e $\text{atraso} = 0$ nos demais pedidos entregues. O horizonte de previsão é o momento da compra; assim, somente informações conhecidas até essa data podem alimentar o modelo.

1.2 Objetivos

Objetivo geral: desenvolver uma solução reprodutível para compreender os atrasos e estimar sua probabilidade antes da entrega.

- Integrar as tabelas sem alterar indevidamente a unidade de análise.
- Tratar dados ausentes, inconsistências, duplicidades e valores extremos.
- Descrever vendas, sazonalidade, clientes, categorias e diferenças regionais.
- Investigar a relação entre distância, peso, preço, frete, pagamento e atraso.
- Comparar Regressão Logística e Random Forest com métricas adequadas.
- Converter os achados em recomendações operacionais mensuráveis.

2. Fundamentação teórica

2.1 Preparação e qualidade dos dados

A preparação de dados transforma registros brutos em uma base coerente para análise. Ela abrange leitura com tipos adequados, padronização, verificação de chaves, tratamento de ausências, detecção de duplicidades, validação de domínios e integração. Em Pandas, operações como merge, groupby, agg e pivot_table permitem combinar e resumir dados. Entretanto, a correção estatística depende de respeitar a cardinalidade das relações. Neste projeto, itens e pagamentos são primeiro resumidos por order_id; somente depois são unidos a pedidos.

Valores ausentes não devem ser tratados automaticamente com uma única regra. Datas de entrega ausentes podem significar pedidos cancelados, em trânsito ou indisponibilidade do registro; como não é possível determinar atraso realizado sem entrega, esses casos são excluídos da modelagem do desfecho. Ausências numéricas em peso e dimensões são imputadas pela mediana dentro do pipeline, calculada apenas no treino. Categorias ausentes recebem o rótulo 'desconhecida'.

Outliers podem representar erro ou uma operação legítima de alto valor. Excluí-los indiscriminadamente reduz a representatividade. O notebook informa quantis, utiliza transformação logarítmica em variáveis assimétricas e aplica RobustScaler, menos sensível a extremos. Regras físicas impossíveis, como peso negativo, são convertidas em ausência. Valores muito altos permanecem rastreáveis e podem ser examinados em análise de sensibilidade.

2.2 Análise exploratória

A análise exploratória de dados (EDA) combina estatísticas descritivas e visualizações para revelar distribuição, sazonalidade, relações, anomalias e possíveis vieses. São calculados volume de pedidos, valor dos produtos comercializados (GMV aproximado), ticket médio, taxa de atraso, prazo médio e dias médios de atraso. Séries mensais avaliam tendência, enquanto a sazonalidade propriamente dita é isolada por mês do ano e por dia da semana da compra, com o cruzamento ano/mês resumido por meio de pivot_table. Gráficos por estado e categoria evidenciam heterogeneidade regional e comercial; boxplots examinam a relação entre distância, peso e atraso; e gráficos de barras comparam a taxa de atraso por forma de pagamento e por faixa de nota média do vendedor, contrastando cada grupo com a média geral.

Associação não implica causalidade. Uma categoria pode apresentar maior atraso por ser mais pesada, ser vendida em regiões distantes ou concentrar vendedores específicos. A

modelagem multivariada ajuda a controlar simultaneamente vários fatores, mas ainda não substitui experimento ou desenho causal.

2.3 Engenharia de atributos e distância

A engenharia de atributos transforma campos originais em representações relevantes: mês, dia da semana e hora da compra; prazo prometido em dias; total de itens; quantidade de vendedores e categorias; preço, frete e relação frete/preço; peso e volume; número e valor de pagamentos; parcelas; estados de origem e destino; e distância aproximada entre centróides de CEP.

A distância geodésica entre o cliente e o vendedor foi estimada por meio da fórmula de Haversine, método amplamente empregado para o cálculo da distância entre dois pontos localizados na superfície terrestre a partir de suas respectivas coordenadas geográficas de latitude e longitude. Para a realização do cálculo, considerou-se o raio médio da Terra igual a 6.371 km. A implementação foi desenvolvida de forma vetorizada com o auxílio da biblioteca NumPy, proporcionando maior eficiência computacional no processamento de um elevado volume de registros. A distância obtida constitui uma aproximação em linha geodésica e, portanto, não representa necessariamente a distância rodoviária efetivamente percorrida durante o processo logístico.

2.4 Modelagem preditiva

A Regressão Logística estima a probabilidade da classe positiva por meio da função logística. É um modelo de referência interpretável: o sinal dos coeficientes mostra a direção da associação, desde que a codificação e a escala sejam consideradas. A Random Forest combina várias árvores treinadas sobre amostras e subconjuntos de atributos, capturando relações não lineares e interações, com menor interpretabilidade direta.

O pré-processamento é encapsulado em Pipeline e ColumnTransformer. Variáveis numéricas recebem imputação mediana e escala robusta; categóricas recebem imputação pela moda e OneHotEncoder com categorias desconhecidas ignoradas. O ajuste ocorre apenas nos dados de treino, prevenindo vazamento entre treino e teste.

2.5 Validação e métricas

Como o objetivo é prever pedidos futuros, a divisão é cronológica: os 80% mais antigos formam o treino e os 20% mais recentes formam o teste. A validação cruzada usa TimeSeriesSplit. Esse desenho é mais realista que uma separação aleatória quando processos logísticos mudam no tempo.

Métrica	Interpretação	Uso no projeto
Precisão	Entre os pedidos sinalizados, proporção realmente atrasada.	Controla falsos alarmes e custo operacional.
Recall	Entre os atrasados, proporção identificada pelo modelo.	Prioriza não deixar atrasos sem intervenção.
F1/F2	Média harmônica; F2 dá mais peso ao recall.	Escolha do limiar conforme custo do negócio.

Métrica	Interpretação	Uso no projeto
ROC-AUC	Capacidade geral de ordenar positivos acima de negativos.	Comparação global entre modelos.
PR-AUC	Precisão-recall em todos os limiares.	Mais informativa quando atrasos são minoria.
Matriz de confusão	VP, FP, VN e FN no limiar escolhido.	Traduz o desempenho em quantidades operacionais.

A acurácia não é usada isoladamente: se os atrasos forem raros, prever todos os pedidos como pontuais pode produzir acurácia elevada e utilidade nula. O limiar de decisão é selecionado no treino pela maior pontuação F2, nunca pelo teste.

2.6 Vazamento de dados e ética

Vazamento ocorre quando o modelo usa informação indisponível no momento da decisão. Datas reais de aprovação, envio e entrega, duração observada, `review_score` e a nota média histórica do vendedor não entram nos preditores. Essa última é derivada das avaliações e, portanto, só existe depois da entrega; o notebook mantém uma lista explícita de variáveis proibidas e interrompe a execução, por meio de `assert`, caso alguma delas seja encontrada entre os atributos selecionados. A avaliação é analisada como consequência associada à experiência, não como causa disponível antecipadamente. Identificadores pessoais e chaves de alta cardinalidade também são excluídos. O modelo deve apoiar priorização, não discriminar consumidores ou regiões; decisões precisam de monitoramento, explicabilidade e revisão humana.

3. Metodologia prática: como cada etapa foi construída

1. Configuração: importação das bibliotecas, definição da semente aleatória única do projeto (`RANDOM_STATE = 42`, propagada ao NumPy e aos estimadores) e identificação automática da pasta contendo os nove arquivos CSV oficiais.
2. Validação dos arquivos: confirmação dos nove CSVs e mensagem clara caso algum esteja ausente.
3. Carga: leitura das datas já convertidas e inspeção de dimensões, tipos, ausências e duplicidades.
4. Qualidade: auditoria de duplicidades exatas, validação de chaves, inspeção dos quantis das variáveis contínuas sujeitas a valores extremos (`p1`, `p25`, `p50`, `p75`, `p95`, `p99` e máximo) e conversão de valores impossíveis em ausentes; na geolocalização, repetições são consolidadas por prefixo de CEP na etapa geográfica.
5. Agregação: itens, pagamentos e avaliações resumidos por pedido antes das junções.
6. Geolocalização: CEPs reduzidos a centróides medianos; cálculo vetorizado da distância cliente-vendedor.
7. Base analítica: integração em `order_id`, definição do alvo e filtro de pedidos entregues com datas válidas.

8. EDA: KPIs, séries mensais, sazonalidade por mês e por dia da semana, atraso por estado e por categoria, e relação do atraso com distância, peso, forma de pagamento e nota média do vendedor.
9. Modelagem: seleção somente de atributos pré-entrega; criação conjunta da matriz de atributos X e da variável-alvo y, com verificações de consistência; pipeline; treino cronológico; e comparação de algoritmos.
10. Avaliação: métricas, curva ROC, curva precisão-recall, matriz de confusão e interpretação de importância. A tabela e o gráfico de importância são produzidos qualquer que seja o algoritmo vencedor, usando o coeficiente na Regressão Logística e a importância média na Random Forest.
11. Recomendações: tradução dos fatores de risco em ações, responsáveis e indicadores de acompanhamento, com os valores numéricos inseridos automaticamente a partir dos resultados da execução.
12. Exportação: salvamento das tabelas de métricas, previsões, importâncias, modelo treinado e das quatorze figuras na pasta outputs, para auditoria e uso no vídeo pitch.

3.1 Dicionário resumido da base analítica

Grupo	Atributos	Justificativa
Temporal	mês, dia da semana, hora, prazo prometido	Captura sazonalidade e folga operacional.
Pedido	itens, vendedores, categorias, preço, frete	Representa complexidade e valor da compra.
Produto	peso, volume	Aproxima dificuldade de manuseio e transporte.
Pagamento	valor, parcelas, quantidade	Caracteriza a transação disponível na compra.
Geográfico	UF cliente, UF vendedor, distância, mesmo estado	Representa percurso e diferenças regionais.
Alvo	delivered_late	1 se entrega real excedeu a estimada; caso contrário, 0.

3.2 Decisões de limpeza

Situação	Tratamento	Motivo
Entrega real/estimada ausente	Excluir apenas da modelagem do alvo	Não é possível classificar atraso realizado. Atinge 2.965 pedidos (2,98% da base).
Peso/dimensão ausente	Imputação mediana dentro do pipeline	Evita perda de pedidos e vazamento. Atinge apenas 2 produtos (0,006%).

Situação	Tratamento	Motivo
Categoria ausente	Rótulo 'desconhecida'	Mantém o registro e explicita a ausência. Atinge 610 produtos (1,85%).
Valores negativos/impossíveis	Converter para NaN e auditar	Não possuem significado físico válido.
Outliers plausíveis	Manter, log-transformar e usar escala robusta	Podem refletir pedidos reais importantes.
Avaliação do cliente e nota do vendedor	Somente EDA	Informação posterior à entrega.
Duplicidades na geolocalização	Consolidar por prefixo de CEP usando a mediana das coordenadas	São 261.831 linhas idênticas; a tabela não possui chave única por linha.

4. Resultados e interpretação

Após a execução integral do notebook com os nove arquivos CSV oficiais, foram obtidos os resultados apresentados a seguir. Os indicadores e métricas foram produzidos diretamente pelo fluxo analítico implementado, garantindo rastreabilidade e reprodutibilidade dos resultados. O notebook imprime, ao final, um bloco de conferência com todos os valores citados nesta seção, o que permite atualizar o relatório após qualquer reexecução.

Indicador	Resultado após execução
Pedidos entregues analisados	96.470
Taxa geral de atraso	8,11%
Valor dos produtos comercializados (GMV aproximado)	R\$ 13.220.248,93
Estado com maior taxa (mínimo 100 pedidos)	AL — 23,93%
Categoria com maior taxa (mínimo 100 pedidos)	audio — 12,93%
Melhor modelo	Regressão Logística
PR-AUC no teste	0,104
Recall no limiar escolhido	0,956 (95,59%)
Precision no limiar escolhido	0,068

Indicador	Resultado após execução
ROC-AUC no teste	0,685
Baseline PR-AUC (prevalência no teste)	0,053
Limiar de decisão adotado	0,333
Clientes únicos	93.350
Ticket médio por pedido	R\$ 159,86
Tempo médio de entrega	12,56 dias
Dias médios de atraso, quando ocorre	9,55 dias
Nota média das avaliações	4,16

Na validação temporal, a Regressão Logística apresentou o melhor desempenho e foi selecionada como modelo final. No conjunto de teste, obteve PR-AUC de 0,104, superior ao baseline de aproximadamente 0,053, e Recall de 0,956. Isso indica que o modelo identificou 976 dos 1.021 pedidos que efetivamente atrasaram no período de teste, cerca de 95,6% do total. Entretanto, a Precision de 0,068 evidencia elevada ocorrência de falsos positivos, já que a triagem sinalizou 14.356 pedidos, equivalentes a 74,4% do conjunto de teste, refletindo o trade-off decorrente da priorização do Recall e da métrica F2. Com limiar de decisão de aproximadamente 0,333, o modelo é mais adequado como ferramenta de triagem e priorização preventiva do que como mecanismo de decisão automática. O ROC-AUC no teste foi de 0,685 e o F1 e o F2 refletem o mesmo desequilíbrio entre precisão e cobertura. Na validação temporal a Random Forest apresentou PR-AUC inferior à da Regressão Logística, motivo pelo qual esta última foi mantida como modelo final. As importâncias e os coeficientes observados indicam associação, não causalidade, e o desempenho deve ser acompanhado ao longo do tempo.

4.1 Fatores adicionais analisados

Além dos recortes por estado e categoria, a análise descritiva examinou três fatores citados explicitamente no enunciado do trabalho: a forma de pagamento, a sazonalidade e a avaliação dos vendedores.

Forma de pagamento. A taxa de atraso foi calculada por meio de pagamento e comparada à média geral. O interesse não está no pagamento em si, que não atua sobre o transporte, mas no tempo até a aprovação do pedido: meios que dependem de compensação bancária consomem parte da folga do prazo prometido antes que a mercadoria seja sequer coletada.

Sazonalidade. A taxa de atraso foi decomposta por mês do ano e por dia da semana da compra, e o cruzamento entre ano e mês foi resumido em uma tabela dinâmica. Essa leitura separa o efeito do calendário do crescimento do volume ao longo do período analisado.

Avaliação dos vendedores. A nota média histórica de cada vendedor foi reconstruída a partir das avaliações dos pedidos em que ele participou e atribuída ao pedido. Os pedidos foram agrupados em faixas de nota e a taxa de atraso foi comparada entre elas. Por se tratar de informação posterior à entrega, essa variável permanece restrita à análise descritiva.

Entre as formas de pagamento, o boleto apresentou a maior taxa de atraso (8,88%) e o voucher a menor (7,09%), contra uma média geral de 8,11%. A amplitude é modesta, inferior a dois pontos percentuais, o que indica influência limitada do meio de pagamento sobre o prazo de entrega, ainda que a direção observada seja compatível com a hipótese de que a espera pela compensação bancária consome parte da folga do prazo prometido.

Na decomposição sazonal, o mês de março concentrou a maior taxa de atraso do período (17,15%). O cruzamento entre ano e mês, porém, mostra que esse resultado não corresponde a um padrão sazonal estável: em março de 2017 a taxa foi de 5,58%, enquanto em março de 2018 alcançou 21,36%. Comportamento semelhante aparece em novembro de 2017 (14,31%). A leitura mais defensável é a de eventos operacionais pontuais, possivelmente associados a picos de demanda ou a mudanças de malha logística, e não de uma sazonalidade recorrente do calendário. Os meses iniciais de 2016 apresentam volume muito baixo e suas taxas não são interpretáveis.

A avaliação dos vendedores produziu a associação mais acentuada de toda a análise descritiva. A taxa de atraso cai de forma monótona ao longo das cinco faixas de nota: 22,40% até 3,0 (857 pedidos), 14,91% entre 3,0 e 3,5 (3.569), 10,06% entre 3,5 e 4,0 (26.130), 7,13% entre 4,0 e 4,5 (58.926) e 3,84% acima de 4,5 (6.985). A razão entre os extremos é de aproximadamente seis vezes, com volume suficiente em todas as faixas.

Esse resultado exige cautela interpretativa. A avaliação é registrada depois da entrega, de modo que parte da associação reflete o próprio atraso deprimindo a nota, e não o inverso. Como a métrica utilizada é a média histórica do vendedor, e não a avaliação do pedido em questão, ela também opera como indicador acumulado de qualidade operacional. Por essa razão a variável permanece restrita à análise descritiva e fora do conjunto de preditores, conforme a política de prevenção de vazamento descrita na seção 2.6.

5. Recomendações estratégicas

As recomendações abaixo correspondem às geradas pela seção 9 do notebook, onde cada ação aparece acompanhada da área responsável, do indicador de acompanhamento e dos valores numéricos obtidos na execução.

- Criar uma fila diária de pedidos por probabilidade de atraso e agir primeiro sobre os casos de alto risco.
- Recalibrar prazos prometidos por rota, categoria, época do ano e histórico operacional, mantendo comunicação transparente.
- Monitorar vendedores e rotas por volume, taxa de atraso e intervalo de confiança, evitando punir grupos com poucas observações; a faixa de vendedores com nota até 3,0 atrasa cerca de seis vezes mais que a faixa acima de 4,5 e concentra apenas 857 pedidos, o que a torna candidata natural a acompanhamento individualizado.
- Acionar transportadoras ou suporte preventivamente quando o risco exceder o limiar definido pelo custo de falsos positivos e falsos negativos.

Reduzir gargalos em produtos pesados, volumosos ou de múltiplos vendedores quando esses fatores forem confirmados pelos resultados.

Monitorar o intervalo entre a compra e a aprovação do pagamento nos meios que apresentaram maior taxa de atraso, recuperando parte da folga do prazo prometido.

Investigar os picos de março de 2018 e novembro de 2017 antes de tratá-los como sazonalidade recorrente, e só então dimensionar capacidade adicional para essas janelas.

Acompanhar mensalmente recall, PR-AUC, calibração, taxa de atraso, reclamações e custo por intervenção.

Retreinar o modelo diante de deterioração e investigar mudanças de processo, região ou mix de produtos.

6. Importância da Ciência de Dados para a logística

A Ciência de Dados converte registros dispersos em uma visão operacional integrada. A análise descritiva revela onde e quando os atrasos se concentram; a modelagem preditiva antecipa risco; e o monitoramento permite medir o efeito das intervenções. O valor não está apenas no algoritmo, mas no ciclo contínuo de coleta, qualidade, previsão, ação e avaliação. Uma solução bem governada melhora a alocação de recursos, reduz decisões reativas e fortalece a experiência do cliente.

7. Limitações

- Os dados abrangem 2016-2018; padrões atuais podem ser diferentes.
- Distância por centróides de CEP é aproximação em linha geodésica, não distância rodoviária.
- Não há dados detalhados de transportadora, clima, tráfego ou capacidade de centros logísticos.
- A análise é observacional e não estabelece causalidade.
- O atraso só é definido para pedidos entregues com datas válidas, o que pode introduzir viés de seleção.

8. Conclusão

O projeto apresenta um fluxo completo e reprodutível, desde a integração das tabelas até a avaliação temporal de modelos. As decisões metodológicas priorizam granularidade correta, prevenção de vazamento e métricas adequadas ao desbalanceamento. Com os nove arquivos CSV oficiais identificados automaticamente pelo notebook, o fluxo produziu evidências sobre quais regiões, categorias e características operacionais estão mais associadas ao atraso, com destaque para a concentração no Norte e Nordeste, para os picos pontuais de março de 2018 e novembro de 2017 e para o forte gradiente entre a nota histórica do vendedor e a taxa de atraso, permitindo transformar probabilidade de risco em ações logísticas acompanhadas por indicadores.

Referências

UNIFECAP. Programming for Data Science (Python & R).

Material da disciplina disponibilizado no Ambiente Virtual de Aprendizagem, 2026.

E-COMMERCE BRASIL. Logística é o maior desafio do e-commerce brasileiro, apontam especialistas. Disponível em: <https://www.ecommercebrasil.com.br/>. Acesso em: 5 ago. 2026.

GERON, Aurélien. Machine Learning com Scikit-Learn e TensorFlow. Rio de Janeiro: Alta Books, 2021.

MCKINNEY, Wes. Python para Análise de Dados: tratamento de dados com Pandas, NumPy e IPython. 2. ed. São Paulo: Novatec, 2019.

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Acesso em: 5 ago. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

WICKHAM, Hadley; GROLEMUND, Garrett. R para Data Science. Rio de Janeiro: Alta Books, 2019.

Link do vídeo pitch

https://youtu.be/W9_imri6YKE